## Об оценке параметров нелинейной регрессии специального вида

Нечаева Мария Леонидовна, 522 группа

Санкт-Петербургский государственный университет Математико-механический факультет Кафедра статистического моделирования

Научный руководитель: д.ф-м.н., проф. Ермаков С.М. Рецензент: ст.научн.сотр. Солнцев В.Н.



Санкт-Петербург 2007г.



 Задача нелинейной регрессии с одной независимой переменной при отсутствии систематической ошибки:

$$y_j = \eta(x_j|\theta) + \varepsilon_j, \quad x_j \in X, \quad j = 0, \dots, N,$$

- $\eta(x|\theta)$  нелинейная функция на  $X \times \Theta$ , задана с точностью до набора параметров  $\theta \in \Theta$ ,  $(\Theta \subseteq \mathbb{R}^m)$ ;
- ullet  $arepsilon_j, \quad j=0,\ldots,N,$  случайные ошибки измерений.

Требуется оценить неизвестные параметры  $\theta$ .

• Рассмотрим конкретную модель:

$$\eta(x|\theta) = \eta(x|\lambda,\omega,\alpha,\beta) = \sum_{i=1}^{p} e^{\lambda_i x} (\alpha_i \cos(\omega_i x) + \beta_i \sin(\omega_i x)),$$

$$\lambda = \{\lambda_i\}_{i=1}^p, \quad \omega = \{\omega_i\}_{i=1}^p, \quad \alpha_i = \{\alpha_i\}_{i=1}^p, \quad \beta = \{\beta_i\}_{i=1}^p,$$
 
$$\theta = \{\lambda, \omega, \alpha, \beta\} - \text{наборы параметров}.$$

## Предполагается:

- ullet число слагаемых для  $\eta(x| heta): \quad p=1,2;$
- ullet в основном  $x_j, \quad j=0,\dots,N,$  равноотстоящие точки из отрезка [0,1];
- $\varepsilon = (\varepsilon_0, \dots, \varepsilon_N)^T : \quad \varepsilon \sim N(0, \sigma^2 I), \quad (\sigma < \infty);$
- $\Theta = \mathbb{R}^{4p}$

$$\hat{\theta} = \left\{ \hat{\lambda}, \; \hat{\omega}, \; \hat{\alpha}, \; \hat{\beta} 
ight\} = \arg\min_{\theta \in \Theta} F(\theta)$$
 — оценка МНК,

где 
$$F(\theta) = \sum_{j=0}^N \left[ y_j - \eta(x_j|\theta) \right]^2$$
 — целевая функция.

## Задача:

- исследовать нахождение оценок  $\hat{ heta}$  несколькими численными методами;
- рассмотреть зависимость ошибки в оценках от погрешности в измерениях и некоторые статистические свойства этих оценок;
- сравнить некоторые результаты оценок методом "Гусеница"-SSA и МНК при условии отсутствия систематической погрешности.



- Для проведения численных экспериментов используется среда MATLAB.
- Рассматриваются 4 метода минимизации.
- Моделирование исходных данных (p=1):
  - ullet выбор истинного набора параметров  $ilde{ heta};$
  - вычисление  $\eta(x_j|\tilde{\theta}) = \eta(x_j|\tilde{\lambda},\tilde{\omega},\tilde{\alpha},\tilde{\beta}) = e^{\tilde{\lambda}x_j} \big(\tilde{\alpha}\cos(\tilde{\omega}x_j) + \tilde{\beta}\sin(\tilde{\omega}x_j)\big)\big), \text{ где } x_j = jh, \quad h = \frac{1}{N}, \quad j = 0,\dots,N;$
  - генерация случайного вектора  $\varepsilon \sim N(0,I)$  и умножение на различные  $\sigma = \sigma(\varepsilon);$
  - ullet вычисление  $y_j = \eta(x_j| ilde{ heta}) + arepsilon_j, \quad j = 0, \dots, N.$
- ullet Начальное приближение для методов:  $heta_0 = ilde{ heta}$  .
- ullet Выбор  $ilde{ heta}$ :
  - несколько наборов, взятых произвольно;
  - ullet фиксируем  $ilde{lpha}=1$ , для  $ilde{\lambda},\, ilde{\omega},\, ilde{eta}$  берем значения в вершинах куба  $[0.5,5]^3$  и случайные точки внутри него.




• Эксперимент: для каждого параметра построение зависимости оценки стандартного отклонения ошибки в оценках параметров  $\hat{\sigma}(\theta) = \{\hat{\sigma}(\lambda), \hat{\sigma}(\omega), \hat{\sigma}(\alpha), \hat{\sigma}(\beta)\}$  от стандартного отклонения для случайной ошибки в измерениях  $\sigma = \sigma(\varepsilon)$ .


Цель эксперимента: исследовать результаты оценки параметров несколькими методами и рассмотреть общий характер зависимости ошибки в оценках от ошибки в измерениях.

- Используемые значения:
  - ullet фиксировано N=50;  $x_0=0,\ x_{50}=1,\ x_j=jh,\ h=1/N,\ j=1,\dots,N-1;$
  - значение  $\sigma(\varepsilon)$  меняется от 0 до 1 с шагом h=0.01, либо h=0.1, и на эти значения умножается каждый смоделированный вектор случайных ошибок;
  - ullet число повторений для вычисления оценки  $\hat{\sigma}( heta)$  M=20.

$$\{\tilde{\lambda} = 3, \tilde{\omega} = 3, \tilde{\alpha} = 1, \tilde{\beta} = 1\}$$

$$\{\tilde{\lambda}=3,\tilde{\omega}=3,\tilde{\alpha}=1,\tilde{\beta}=1\} \qquad \quad \{\tilde{\lambda}=5,\tilde{\omega}=0.5,\tilde{\alpha}=1,\tilde{\beta}=0.5\}$$







- H матрица вторых производных целевой функции  $F(\theta)$  по параметрам при  $\sigma(\varepsilon)=0$  в точке истинных значений  $ilde{ heta};$
- $\lambda_{min}, \, \lambda_{max}$  минимальное и максимальное собственные числа матрицы H;
- ullet  $d=\lambda_{min}/\lambda_{max}$  число обусловленности матрицы H.

**Результат:** у "плохих" наборов параметров число обусловленности много меньше по сравнению с "хорошими" наборами.

"хорошие" наборы					"плохие" наборы				
$\tilde{\lambda}$	$\tilde{\omega}$	$\tilde{\alpha}$	$\tilde{eta}$	d	$\tilde{\lambda}$	$\tilde{\omega}$	$\tilde{\alpha}$	$ ilde{eta}$	d
2	3	1	4	$0.34 \cdot 10^{-3}$	1	1	1	1	$0.12 \cdot 10^{-5}$
3	3	1	1	$0.39 \cdot 10^{-3}$	0.5	0.5	1	5	$0.53 \cdot 10^{-7}$
5	5	1	0.5	$0.27 \cdot 10^{-3}$	0.3	2	1	3	$0.32 \cdot 10^{-5}$
0.5	5	1	5	$0.72 \cdot 10^{-2}$	4.3	1.4	1	1.1	$0.45 \cdot 10^{-5}$
8.0	4.4	1	2.6	$0.13 \cdot 10^{-1}$	5	0.5	1	5	$0.15 \cdot 10^{-8}$
0.5	5	1	5	$0.72 \cdot 10^{-3}$	1.7	8.0	1	0.9	$0.29 \cdot 10^{-5}$

- При  $\varepsilon \backsim N(0, \sigma^2 I)$  оценки МНК являются эффективными, асимптотически состоятельными и нормальными.
- ullet Эксперимент: при различных значениях  $\sigma(arepsilon)$  и N для некоторых параметров
  - построены гистограммы одномерных распределений ошибок в оценках параметров;
  - вычислена оценка смещения оценок МНК;
  - оценена матрица ковариаций вектора погрешности в оценках.
- Используемые значения:
  - рассмотрено N = 5, 10, 50;
  - значение  $\sigma(\varepsilon) = 0.01, \ 0.1, \ 0.2, \ 0.5, \ 1;$
  - ullet фиксировано M=150- объем выборки оценок.

• В случае равноотстоящих точек  $x_j$ ,  $j=0,\dots,N$  функция  $\eta(x|\theta)$  удовлетворяет уравнению:

$$\eta(x_j|\theta) = a\eta(x_{j-1}|\theta) + b\eta(x_{j-2}|\theta), \ j = 2,\dots, N.$$

- ullet Исходный временной ряд  $Y=(y_0,\ldots,y_N).$
- Эксперимент: метод "Гусеница"-SSA
  - выбираем L (1 < L < N+1); строим матрицу вложения X;
  - $\lambda_i$  с. ч.,  $U_i$  с. в. матрицы  $\mathbb{X}\mathbb{X}^{\mathrm{T}},\ i=1,\ldots,L,$   $\lambda_1\geq\ldots\geq\lambda_L\geq0,\quad d=\max\{i:\lambda_i>0\},$   $\mathbb{X}=\sum_{i=1}^d\sqrt{\lambda_i}U_iV_i^{\mathrm{T}}$  SVD-разложение матрицы  $\mathbb{X}$ ;
  - ullet берем матрицу  $\hat{\mathbb{X}} = \sqrt{\lambda_1} U_1 V_1^{\mathrm{T}} + \sqrt{\lambda_2} U_2 V_2^{\mathrm{T}}$ ;
  - ullet  $\hat{Y}=(\hat{y}_0,\ldots,\hat{y}_N)$  ряд, полученный после диагонального усреднения матрицы  $\hat{\mathbb{X}}$ .

## MHK

- находим  $\hat{\theta} = \{\hat{\lambda}, \hat{\omega}, \hat{\alpha}, \hat{\beta}\}$  оценку  $\theta = \{\lambda, \omega, \alpha, \beta\}$ ;
- ullet вычисляем  $(\hat{\eta}_0,\dots,\hat{\eta}_N)$ :

$$\hat{\eta}_j = \eta(x_j|\hat{\theta}) = e^{\hat{\lambda}x_j} \left( \hat{\alpha}\cos(\hat{\omega}x_j) + \hat{\beta}\sin(\hat{\omega}x_j) \right).$$

- Используемые значения:
  - фиксировано N = 50, L = 25;
  - ullet значение  $\sigma=\sigma(arepsilon)$  меняется от 0 до 2 с шагом h=0.1;
  - ullet число повторений эксперимента M=20.
- ullet Для оценок  $(\hat{y}_0^{i,\sigma},\ldots,\hat{y}_N^{i,\sigma})$  и  $(\hat{\eta}_0^{i,\sigma},\ldots,\hat{\eta}_N^{i,\sigma})$  вычисляются:
  - ullet отклонения от истинных значений в каждой точке  $(j=0,\dots,N)$

$$res_j^{\sigma} S = \frac{1}{M} \sum_{i=1}^{M} (\hat{y}_j^{i,\sigma} - \eta(x_i | \tilde{\theta})),$$

$$res_j^{\sigma} M = \frac{1}{M} \sum_{i=1}^{M} (\hat{\eta}_j^{i,\sigma} - \eta(x_j | \tilde{\theta}));$$


• средняя сумма квадратов отклонений от истинных значений


$$res^{\sigma}S = \frac{1}{M} \sum_{i=1}^{M} \left[ \frac{1}{N} \sum_{j=1}^{N} (\hat{y}_{j}^{i,\sigma} - \eta(x_{j}|\tilde{\theta}))^{2} \right],$$

$$res^{\sigma} M = \frac{1}{M} \sum_{i=1}^{M} \left[ \frac{1}{N} \sum_{j=1}^{N} (\hat{\eta}_{j}^{i,\sigma} - \eta(x_{j}|\tilde{\theta}))^{2} \right].$$


$$\{\tilde{\lambda}=0.5,\ \tilde{\omega}=7,\ \tilde{\alpha}=1,\ \tilde{\beta}=5\}$$

ullet вид ряда и отклонения в каждой точке  $(\sigma(arepsilon)=1)$ :







• зависимость средней суммы квадратов отклонений от истинных значений от  $\sigma(arepsilon)$ :



- ullet Оценки МНК можно строить, когда точки  $x_j \in [a,b]$ ,  $j=0,\ldots,N$  не являются равноотстоящими.
- Исходные данные: на сетке из равноотстоящих точек  $x_j \in [0,1], \ j=0,\dots,N$  "выкидываем" часть значений  $x_p,\dots,x_{p+k}$  (пропущенные наблюдения) и моделируем значения  $y_0,\dots,y_p,y_{p+k},\dots,y_N.$
- ullet Вид ряда для  $\{ ilde{\lambda}=2, ilde{\omega}=3, ilde{lpha}=1, ilde{eta}=4\}$  (выделен промежуток пропущенных точек,  $p=25,\,k=10$ ):



Зависимость погрешности в оценке неизвестных параметров от ошибки в измерениях для модели без пропусков (синим) и при наличии пропущенных наблюдений (красным):



**Результат:** с увеличением числа пропущенных наблюдений ошибка растет.

Численные эксперименты в работе позволяют сделать выводы:

- методы, предлагаемые пакетом MATLAB, позволяют достаточно уверенно находить оценки МНК, когда матрица H хорошо обусловлена (число обусловленности не ниже порядка  $10^{-3}$ ), иначе требуется оптимизация методов;
- удалось проследить зависимость ошибок в оценках от ошибок в исходных данных; установлено, что оценки МНК нормальны при сравнительно небольшом числе наблюдений;
- при сравнении результатов отделения сигнала от шума методом "Гусеница"-SSA и восстановления регрессии с помощью МНК отмечено, что МНК дает меньшее отклонение от истинного значения, и это различие растет с ростом  $\sigma$ ;
- когда из равноотстоящих точек часть наблюдений пропущены, методы также работают, но ошибка в оценках, безусловно, увеличивается и зависит от положения пропущенных точек.

