

Анализ кривых дожития в условиях цензурирования с применением в нейрохирургии

Матвеева Юлия Алексеевна, гр. 522

Санкт-Петербургский государственный университет
Математико-механический факультет
Кафедра статистического моделирования

Научный руководитель: к.ф.-м.н., доц. Алексеева Н.П.

Рецензент: к.ф.-м.н. Коробейников А.И.



Санкт-Петербург
2011г.

- \tilde{Z}, \tilde{n} — независимые случайные величины.
- Носитель \tilde{n} содержится в множестве натуральных чисел.
- $\{n_k\}_{k=1}^m$ — реализации повторных независимых копий $\{\tilde{n}_k\}_{k=1}^m$ величины \tilde{n} .
- $\{Z_j\}$ — реализации повторных независимых копий $\{\tilde{Z}_j\}$ величины \tilde{Z} .

Выборка $\{Z_j\}$ разбита на группы в соответствии с реализациями $\{n_k\}_{k=1}^m$:

$$\overbrace{Z_1, \dots, Z_{n_1}}, \quad \overbrace{Z_{n_1+1}, \dots, Z_{n_1+n_2}}, \quad \overbrace{Z_{n_1+n_2+1}, \dots, Z_{n_1+n_2+n_3}},$$

$$\dots, \overbrace{Z_{n_1+\dots+n_{m-1}+1}, \dots, Z_{n_1+\dots+n_m}},$$

- $\tilde{M}(n) = \sup\{x : \hat{F}_n(x) \leq \frac{1}{2}\}$ — выборочная медиана, построенная по выборке объема n из величины \tilde{Z} .
- M_k — реализация выборочной медианы k -й группы.

Медианное цензурирование:

Величины $\{Z_j\}$ не наблюдаются, а наблюдаются лишь наборы

$$(\mathcal{M}_k, n_k).$$

Медианное цензурирование:

Величины $\{Z_j\}$ не наблюдаются, а наблюдаются лишь наборы

$$(\mathcal{M}_k, n_k).$$

Задача:

Построение и анализ (непараметрической) оценки функции распределения

$$F_0(x) = P(\tilde{Z} \leq x)$$

в условиях медианного цензурирования.

Метод:

Метод максимального правдоподобия.

- **Правое цензурирование:** Наблюдается величина

$$\tilde{Y} = \left[\tilde{C} = \min\{\tilde{Z}, \tilde{T}\}, \tilde{\delta} = 1_{\{\tilde{Z} \leq \tilde{T}\}} \right], \text{ где } \tilde{Z} \text{ и } \tilde{T} \text{ независимы.}$$

- **Интервальное цензурирование типа K :**

$$K \geq 1, \quad \tilde{T} = \{0 =: \tilde{T}_0 < \tilde{T}_1 < \dots < \tilde{T}_K < \tilde{T}_{K+1} := \infty\},$$

$$\tilde{Z} \text{ и } \tilde{T} \text{ независимы,}$$

$$\tilde{\delta}_k = 1_{\{\tilde{Z} \in (\tilde{T}_{k-1}, \tilde{T}_k)\}}, k = 1, \dots, K+1.$$

Наблюдается $(\tilde{T}, \tilde{\delta})$.

- **Интервальное цензурирование смешанного типа:** Определяется как смесь (по K) интервальных цензурирований типа K . $\tilde{K} \geq 1$ — целочисленная случайная величина.

$$\tilde{T} = \{0 =: \tilde{T}_{(0,K)} < \tilde{T}_{(1,K)} < \dots < \tilde{T}_{(K,K)} < \tilde{T}_{(K+1,K)} := \infty\}, K = 1, 2, 3, \dots,$$

$$\tilde{Z} \text{ и } (\tilde{T}, \tilde{K}) \text{ независимы,}$$

$$\tilde{\delta}_{(k,K)} = 1_{\{\tilde{Z} \in (\tilde{T}_{(k-1,K)}, \tilde{T}_{(k,K)})\}}, k = 1, \dots, K+1, K = 1, 2, 3, \dots$$

Наблюдается $(\tilde{K}, \tilde{\delta}_{(\cdot, \tilde{K})}, \tilde{T}_{(\cdot, \tilde{K})})$.

J. Sun. *The Statistical Analysis of Interval-censored Failure Time Data*, Springer, 2006.

Задача непараметрического оценивания функции распределения, вообще говоря, бесконечномерна.

Структура работы:

- 1 Сведение задачи к конечномерной и анализ ее свойств (существование решения, выпуклость).
- 2 Явное аналитическое решение задачи в частном случае и анализ асимптотических свойств соответствующей оценки.
- 3 Анализ асимптотических свойств оценки в общем случае (состоятельность, несмещенность, асимптотическая нормальность).
- 4 Аппробация разработанного метода на реальных данных.

Лемма

Введем порядковые статистики $\tilde{Z}_{[1]} \leq \tilde{Z}_{[2]} \leq \dots \leq \tilde{Z}_{[n]}$. Тогда для выборочной медианы, соответствующей выборке $\{\tilde{Z}_j\}_{j=1}^n$, верно следующее:

$$\tilde{\mathcal{M}}(n) = \tilde{Z}_{[l]}, \quad l = \left\lceil \frac{n+1}{2} \right\rceil.$$

Лемма

Функция распределения $G_n(x)$ выборочной медианы $\tilde{\mathcal{M}}(n)$ имеет вид:

$$G_n(x) = P(\tilde{\mathcal{M}}(n) \leq x) = \Psi_n[F_0(x)],$$

где $\Psi_n(\cdot)$ — регуляризованная неполная бета-функция $B(a_n, b_n)$ с параметрами $a_n = \lceil \frac{n+1}{2} \rceil$ и $b_n = \lfloor \frac{n+1}{2} \rfloor$:

$$\Psi_n(y) = \kappa_n \int_0^y t^{\lceil \frac{n+1}{2} \rceil - 1} (1-t)^{\lfloor \frac{n+1}{2} \rfloor - 1} dt, \quad y \in [0, 1],$$

$$\kappa_n = \frac{\Gamma(n+1)}{\Gamma(\lceil \frac{n+1}{2} \rceil) \Gamma(\lfloor \frac{n+1}{2} \rfloor)}.$$

$$L_N(F \mid \{(\mathcal{M}_k, n_k)\}_{k=1}^m) = \prod_{k=1}^m P_{\tilde{\mathcal{M}}(n_k)}(\mathcal{M}_k) P(\tilde{n} = n_k).$$

$$P_{\tilde{\mathcal{M}}(n_k)}(\mathcal{M}_k) = P(\tilde{\mathcal{M}}(n_k) = \mathcal{M}_k). \quad (1)$$

$$P_{\tilde{\mathcal{M}}(n_k)}(\mathcal{M}_k) = p_{\tilde{\mathcal{M}}(n_k)}(\mathcal{M}_k). \quad (2)$$

$$L_N(F \mid \{(\mathcal{M}_k, n_k)\}_{k=1}^m) = \prod_{k=1}^m P_{\tilde{\mathcal{M}}(n_k)}(\mathcal{M}_k) P(\tilde{n} = n_k).$$

$$P_{\tilde{\mathcal{M}}(n_k)}(\mathcal{M}_k) = P(\tilde{\mathcal{M}}(n_k) = \mathcal{M}_k). \quad (1)$$

$$P_{\tilde{\mathcal{M}}(n_k)}(\mathcal{M}_k) = p_{\tilde{\mathcal{M}}(n_k)}(\mathcal{M}_k). \quad (2)$$

- \mathfrak{D} — множество распределений, имеющих атомы в точках наблюдения,
- \mathfrak{E} — множество соответствующих им функций распределения.

Задача приобретает вид нахождения:

$$\hat{F}_m = \operatorname{argmax}_{F \in \mathfrak{E}} l_m(F),$$

$$l_m(F) = \sum_{k=1}^m \log \left(\Psi_{n_k} [F(\mathcal{M}_k)] - \Psi_{n_k} [F(\mathcal{M}_k - 0)] \right).$$

Утверждение

- 1 На множестве \mathfrak{D} распределений, имеющих атомы в наблюдаемых медианах, максимум функции правдоподобия достигается.
- 2 Максимайзеры функции правдоподобия сосредоточены на конечном множестве наблюдаемых точек $\{\mathcal{M}_1, \dots, \mathcal{M}_m\}$ и присваивают каждой из них положительную вероятность.

Утверждение

- ❶ На множестве \mathfrak{D} распределений, имеющих атомы в наблюдаемых медианах, максимум функции правдоподобия достигается.
- ❷ Максимайзеры функции правдоподобия сосредоточены на конечном множестве наблюдаемых точек $\{\mathcal{M}_1, \dots, \mathcal{M}_m\}$ и присваивают каждой из них положительную вероятность.

Упорядочим точки наблюдения $\mathcal{M}_1 < \mathcal{M}_2 < \dots < \mathcal{M}_s$ и перейдем к новым переменным:

$$x_\nu = F(\mathcal{M}_\nu), \quad \nu = 1, \dots, s,$$

$$\Xi_m := \sum_{\nu=1}^s \sum_{k: \mathcal{M}_k = \mathcal{M}_\nu} \log(\Psi_{n_k}[x_\nu] - \Psi_{n_k}[x_{\nu-1}]) \rightarrow \max,$$

$$x_0 := 0 < x_1 < \dots < x_s = 1.$$

Утверждение

- ❶ На множестве \mathfrak{D} распределений, имеющих атомы в наблюдаемых медианах, максимум функции правдоподобия достигается.
- ❷ Максимайзеры функции правдоподобия сосредоточены на конечном множестве наблюдаемых точек $\{\mathcal{M}_1, \dots, \mathcal{M}_m\}$ и присваивают каждой из них положительную вероятность.

Упорядочим точки наблюдения $\mathcal{M}_1 < \mathcal{M}_2 < \dots < \mathcal{M}_s$ и перейдем к новым переменным:

$$x_\nu = F(\mathcal{M}_\nu), \quad \nu = 1, \dots, s,$$

$$\Xi_m := \sum_{\nu=1}^s \sum_{k: \mathcal{M}_k = \mathcal{M}_\nu} \log(\Psi_{n_k}[x_\nu] - \Psi_{n_k}[x_{\nu-1}]) \rightarrow \max,$$

$$x_0 := 0 < x_1 < \dots < x_s = 1.$$

Утверждение

Функция $\Xi_m(\cdot)$ является строго выпуклой (вниз).

Утверждение

В случае групп одинакового объема n максимум функции правдоподобия достигается на единственной функции распределения, которая определяется формулой

$$\hat{F}_m(x) = \Psi_n^{-1}(\hat{G}_m(x)).$$

Здесь $\hat{G}_m(x)$ эмпирическая функция распределения медианы $\tilde{M}(n)$, построенная по наблюдениям $\mathcal{M}_1, \dots, \mathcal{M}_m$.

Факторы, облегчающие задачу нахождения оценки \hat{F}_m :

- Строгая монотонность функции $\Psi_n(\cdot)$ на интервале $[0, 1]$ поиска решений.
- Промежутки постоянства функции распределения $\hat{G}_m(x)$ совпадают с промежутками постоянства функции распределения $\hat{F}_m(x)$.
- Наличие затабулированных как прямых, так и обратных значений функции $\Psi_n(\cdot) = B(\lceil \frac{n+1}{2} \rceil, \lfloor \frac{n+1}{2} \rfloor)$.

Теорема

Оценка $\hat{F}_m(\cdot) = \Psi_n^{-1}(\hat{G}_m(\cdot))$ как оценка функции распределения $F_0(\cdot)$ исходной случайной величины \tilde{Z} обладает следующими свойствами:

- **равномерная состоятельность :**

$$\sup_{x \in \mathbb{R}} |\hat{F}_m(x) - F_0(x)| \xrightarrow{a.s.} 0 \quad \text{при } m \rightarrow \infty.$$

- **равномерная асимптотическая несмещенность :**

$$E \sup_{x \in \mathbb{R}} |\hat{F}_m(x) - F_0(x)| \xrightarrow{m \rightarrow \infty} 0.$$

- В точках x , где $0 < F_0(x) < 1$, оценка $\hat{F}_m(x) = \Psi_n^{-1}[\hat{G}_m(x)]$ является **асимптотически нормальной** :

$$\mathcal{L}(\sqrt{m}(\hat{F}_m(x) - F_0(x))) \Rightarrow N(0, D),$$

где
$$D = \frac{\Psi_n[F_0(x)](1 - \Psi_n[F_0(x)])}{(\Psi'_n[F_0(x)])^2}.$$

- $\{\tilde{Z}_j\}$ — ненаблюдаемые независимые копии случайной величины \tilde{Z} с конечным носителем,
- \tilde{n}_k — независимые от $\{\tilde{Z}_j\}$ и между собой копии случайной величины \tilde{n} с конечным носителем,
- известны пары реализаций $\{(\mathcal{M}_k, n_k)\}_{k=1}^m$.
- $\hat{F}_m(\cdot)$ — оценка максимального правдоподобия функции распределения $F_0(\cdot)$ случайной величины \tilde{Z} .

Равномерная сильная состоятельность:

Теорема

В перечисленных условиях $\hat{F}_m(\cdot)$ является равномерно сильно состоятельной оценкой функции распределения $F_0(\cdot)$ случайной величины \tilde{Z} :

$$\sup_{x \in \mathbb{R}} |\hat{F}_m(x) - F_0(x)| \xrightarrow{\text{a.s.}} 0 \quad \text{при} \quad m \rightarrow \infty.$$

Техника доказательства: Schick, A., Yu, Q., 2000.

Равномерная асимптотическая несмещенность:**Следствие**

Оценка $\hat{F}_m(x)$ является равномерно асимптотически несмещенной:

$$E \sup_{x \in \mathbb{R}} |\hat{F}_m(x) - F_0(x)| \xrightarrow{m \rightarrow \infty} 0.$$

$Z = \{z_1 < z_2 < \dots < z_{s-1} < z_s\}$ — конечный носитель величины \tilde{Z} .

$$\mathbf{x} = \begin{pmatrix} F(z_1) \\ \vdots \\ F(z_{s-1}) \end{pmatrix} =: \mathbf{F}(\mathbf{z}), \quad \mathbf{x}_0 = \mathbf{F}_0(\mathbf{z}), \quad \hat{\mathbf{x}}_m = \hat{\mathbf{F}}_m(\mathbf{z}).$$

$$0 =: x_0 < x_1 < \dots < x_{s-1} < x_s := 1.$$

Утверждение

Введем матрицу вторых производных

$$\Sigma_m(\mathbf{x}) = \Sigma_m(F) = \left(\frac{\partial^2 \Xi_m}{\partial x_i \partial x_j}(\mathbf{x}) \right)_{i,j=1}^{s-1}.$$

Информационная матрица Фишера

$$J_0 = \mathbf{E} \left[\frac{1}{m} \nabla \Xi_m(\mathbf{x}_0) (\nabla \Xi_m(\mathbf{x}_0))^T \right] = -\mathbf{E} \left[\frac{1}{m} \Sigma_m(\mathbf{x}_0) \right]$$

является положительно определенной.

Асимптотическая нормальность:

Теорема

- ❶ Оценка $\hat{F}_m(x)$ является асимптотически нормальной:

$$\mathcal{L} \left(\sqrt{m} \Delta(\hat{F}_m, F_0) \right) \Rightarrow N(0, J_0^{-1}),$$

$$\text{где } \Delta(\hat{F}_m, F_0) = \begin{pmatrix} \hat{F}_m(z_1) - F_0(z_1) \\ \vdots \\ \hat{F}_m(z_{s-1}) - F_0(z_{s-1}) \end{pmatrix}.$$

- ❷ $-\frac{1}{m} \Sigma_m(\hat{F}_m)$ является сильно состоятельной оценкой J_0 :

$$-\frac{1}{m} \Sigma_m(\hat{\mathbf{x}}_m) \xrightarrow{a.s.} -\mathbf{E} \left[\frac{1}{m} \Sigma_m(\mathbf{x}_0) \right] = J_0 \quad \text{при } m \rightarrow \infty.$$

Данные:

Военной академией им. Кирова были предоставлены данные о времени жизни пациентов с различными типами опухолей головного мозга, подвергнутых различным способам хирургического лечения. Данные были медианно-цензурированными, то есть имели вид набора пар

$$\{(\mathcal{M}_k, n_k)\}.$$

- язык программирования и среда разработки: **R** ;
- нахождение значений бета-функции: функция **Rbeta** из библиотеки **zipfR** упомянутой среды;
- решение оптимизационной задачи нахождения оценки максимального правдоподобия: функция **constrOptim** из базовой библиотеки упомянутой среды
- использован алгоритм оптимизации:
 - метод деформируемых многогранников (Nelder-Mead).

