

Использование метода поиска наилучшей проекции для анализа сингулярного спектра

Ломтев Максим Александрович, гр. 522

Санкт-Петербургский государственный университет
Математико-механический факультет
Кафедра статистического моделирования

Научный руководитель: к.ф.-м.н., доцент Голяндина Н. Э.
Рецензент: к.ф.-м.н., доцент Коробейников А. И.



Санкт-Петербург
2013г.

Постановка задачи

$F_N = (f_0, \dots, f_{N-1})$ — временной ряд. Пусть $F_N = F_N^{(1)} + F_N^{(2)}$.

Задача: по наблюдаемому ряду F_N найти, может быть, приближенно, $F_N^{(1)}$ и $F_N^{(2)}$.

Говорим, что **метод разделяет ряды**, если он может решить задачу нахождения слагаемых.

Метод: SSA (анализ сингулярного спектра).

Требуется: рассмотреть модификацию SSA, которая в ряде случаев улучшает разделимость рядов.

Общая схема методов

Вход — ряд $F_N = (f_0, \dots, f_{N-1})$ длины N .

Схема методов, связанных с SSA:

- Выбрать *длину окна* L и сопоставить ряду *траекторную матрицу* \mathbf{X} размера $L \times K$, $L \leq K = N - L + 1$, из отрезков ряда длины L в качестве столбцов. Траекторной матрице соответствует пространство \mathcal{L} строк размерности $d \leq L$.
- Разложить траекторную матрицу в сумму матриц $\mathbf{X} = \mathbf{X}_1 + \dots + \mathbf{X}_d$, или, эквивалентно, найти базис $\{S_1, \dots, S_d\}$ пространства \mathcal{L} .
- Сгруппировать матрицы в две группы или, эквивалентно, разбить базис на две части.
- Получить разложение $F = F^{(1)} + F^{(2)}$ на основе группировки.

Методы SSA и ICA

SSA: Базис находится с помощью сингулярного разложения траекторной матрицы.

ICA: Базис находится с помощью поиска наилучшей проекции (Projection Pursuit, PP) для решения задачи анализа независимых компонент (Independent Component Analysis, ICA).

SSA-ICA: ICA применяется к подпространству траекторного пространства, найденному с помощью SSA.

Пусть $F = F^{(1)} + F^{(2)} + F^{(3)}$.

Результат SSA: $F = \tilde{F}^{(1,2)} + \tilde{F}^{(3)},$

Результат ICA: $\tilde{F}^{(1,2)} = \tilde{F}^{(1)} + \tilde{F}^{(2)},$

Результат SSA-ICA: $F = \tilde{F}^{(1)} + \tilde{F}^{(2)} + \tilde{F}^{(3)}.$

Далее для простоты будем считать, что $F^{(3)} = 0$, $F^{(1,2)} = F$.

Разделимость как разделение подпространств

Ряды $F_N = F_N^{(1)} + F_N^{(2)}$ — ряды длины N , L — длина окна.
 \mathbf{X} , $\mathbf{X}^{(1)}$, $\mathbf{X}^{(2)}$ — траекторные матрицы $L \times K$, $\mathbf{X} = \mathbf{X}^{(1)} + \mathbf{X}^{(2)}$.
 \mathcal{L} , $\mathcal{L}^{(1)}$, $\mathcal{L}^{(2)}$ — пространства строк траект. матриц, $\mathcal{L} = \mathcal{L}^{(1)} \oplus \mathcal{L}^{(2)}$.
 r , r_1 , r_2 — ранги траекторных матриц, они же размерности пространств строк, $r = r_1 + r_2$.

Пусть метод SSA находит базис пространства \mathcal{L} .
 Будем говорить, что базис \mathcal{L} **разделяет подпространства**, если его можно разбить на базисы подпространств $\mathcal{L}^{(1)}$ и $\mathcal{L}^{(2)}$.

Задача метода SSA-ICA — найти такой разделяющий базис \mathcal{L} .
 Если разделяющий базис найден, то мы получаем $F_N^{(1)}$ и $F_N^{(2)}$ точно.
 Назовем вектора “**правильными**”, если они составляют разделяющий базис.

Слабая и сильная разделимость

Проблема: результат метода не единственен (например, при совпадающих сингулярных числах сингулярное разложение не единственно).

Слабая разделимость: среди всех базисов, которые являются результатом метода, ***существует разделяющий***.

Сильная разделимость: ***любой*** базис, являющийся результатом метода, ***разделяющий***.

Для применения нужна сильная разделимость.

SSA приближенно слабо разделяет тренд и периодическую компоненты, гармоники с разными периодам, сигнал и шум.

Но: компоненты с одинаковым вкладом могут смешаться (нет сильной разделимости).

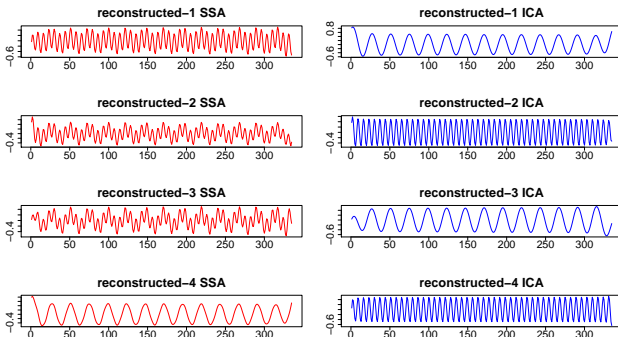
ICA: не умеет отделять сигнал от шума, несколько хуже разделяет детерминированные компоненты.

Но: может разделять компоненты с одинаковым вкладом.

Пример отсутствия сильной разделимости

$$f_n = A \sin(2\pi\omega_1 n + \gamma_1) + A \sin(2\pi\omega_2 n + \gamma_2), \quad (1)$$

$$\mathbf{X} = \mathbf{X}_1 + \mathbf{X}_2 + \mathbf{X}_3 + \mathbf{X}_4. \quad (2)$$



Структура работы

- Сначала задача разделения решается для разделения подпространств, не обязательно являющихся траекторными. Если размерность подпространств равна 1, то можно говорить о разделении векторов. Результаты продемонстрированы на примере разделения двух векторов.
- Формулируются алгоритмы SSA-ICA для рядов.
- Полученные для разделения подпространств результаты используются для получения условий точной и асимптотической разделимости рядов.
- Примеры.

Будем формально вводить определения и формулировать результаты только для точной разделимости.

Применение РР для разделения векторов, пример


S_1 и S_2 — синусы с периодами T_1 и T_2 .

$$S_1(\alpha) = S_1 \cos \alpha + S_2 \sin \alpha, \quad S_2(\alpha) = -S_1 \sin \alpha + S_2 \cos \alpha.$$


Разделяющий базис $\{S_1(\alpha), S_2(\alpha)\}$ соответствует $\alpha = 0$.

Применим SVD к $[S_1(\alpha) : S_2(\alpha)]$ — получим случайное направление.

Формально применим ICA — получим $\alpha = 0$.



Скаттерплоты $(S_1(\alpha), S_2(\alpha))$



Формы плотностей проекций
на ось X

РР для векторов: Критерий из ІСА

$$\|X\|_P = \sqrt{\frac{1}{K} \sum_{n=1}^K x_n^2}.$$

$$Z = (z_1, \dots, z_K)^T, \bar{Z} = \frac{1}{K} \sum_{n=1}^K z_n = 0, \|Z\|_P = 1.$$

Критерий “правильности” вектора:

$$J(Z) = \left[-\frac{1}{K} \sum_{n=1}^K G(z_n) + C_\nu \right]^2, C_\nu = \mathbb{E}G(\nu), \nu \in N(0, 1),$$

$G(u)$ — чётная, трижды дифференцируемая.

Пусть базис $\{S_1, S_2\}$ — разделяющий, центрированный, ортонормированный. Тогда $\{\pm S_1 \text{ или } 2, \pm S_2 \text{ или } 1\}$ тоже разделяющий.

$$S_1(\alpha) = S_1 \cos \alpha + S_2 \sin \alpha, S_2(\alpha) = -S_1 \sin \alpha + S_2 \cos \alpha.$$

Тогда базис $\{S_1(\alpha), S_2(\alpha)\}$ является разделяющим при $\alpha = 0, \pi/2, \pi, 3\pi/2$.


Вопрос: максимумы $J(S_1(\alpha))$ достигаются на α , соответствующих векторам из разделяющего базиса?

ICA для векторов: Пример

S_1 и S_2 — синусы с периодами T_1 и T_2 .

Поведение $J(S_1(\alpha))$ для разных G . Соответствие максимумов векторам из разделяющего базиса ($\alpha = 0, \pi/2, \pi, 3\pi/2, 2\pi$).

$$\sin(2\pi n/17 + \pi/4) \text{ and } \sin(2\pi n/15 + \pi/4)$$



Будем рассматривать $G(u) = u^4$.

ICA для векторов: условия разделения

Поиск разделяющего базиса по ICA — последовательная задача

максимизации функционала $J(Z) = \left[-\frac{1}{K} \sum_{n=1}^K G(z_n) + C_\nu \right]^2$, где $Z \in \mathcal{L}$.

Пусть ортонормированный и центрированный базис $\{S_1, S_2\}$ является разделяющим, $S_1(\alpha) = S_1 \cos \alpha + S_2 \sin \alpha$.

Утверждение

Для того чтобы максимум $J(S_1(\alpha))$ достигался при $\alpha = 0, \pi/2$, необходимо и достаточно:

$$\sum_{n=1}^K G'(s_{n,1}) s_{n,2} = 0, \quad \sum_{n=1}^K G'(s_{n,2}) s_{n,1} = 0,$$

$$\left[-\frac{1}{K} \sum_{n=1}^K G(s_{n,1}) + \mathbb{E}G(\nu) \right] \sum_{n=1}^K \left[G'(s_{n,1}) s_{n,1} - G''(s_{n,1}) s_{n,2}^2 \right] < 0,$$

$$\left[-\frac{1}{K} \sum_{n=1}^K G(s_{n,2}) + \mathbb{E}G(\nu) \right] \sum_{n=1}^K \left[G'(s_{n,2}) s_{n,2} - G''(s_{n,2}) s_{n,1}^2 \right] < 0.$$

ICA для векторов: итоги и проблемы

Для подпространств, заданных центрированными и ортонормированными базисами:

- Были получены условия слабой и асимптотической делимости подпространств в общем виде.
- Условия были проверены для разделения центрированных подпространств, порожденных гармониками (сильная), линейной функцией и экспонентой (асимптотическая).

Следующая задача: использование результатов для траекторных пространств рядов.

Если траекторные матрицы имеют нулевые средние по строкам, то ICA применяется прямо к траекторной матрице (к базису строк).

Если траекторная матрица X не центрирована по строкам, то есть два способа применения ICA:

- **SSA-ICA с центрированием:** применение ICA к центрированной по строкам матрице,
- **SSA-ICA:** без внешнего центрирования, центрирование внутри максимизируемого функционала.

Базовый метод SSA-ICA

Функционал: $J_{\text{nc}}(Q) = \left(-\frac{1}{K} \sum_{l=1}^K G\left(\frac{q_l - \bar{Q}}{\text{s.d.}(Q)}\right) + \mathbb{E}G(\nu) \right)^2$.

Пусть ранг $\mathbf{X} - \bar{\mathbf{X}}$ равен рангу \mathbf{X} . Обозначим ранг r .

А. Оптимизационная задача с внутренним центрированием для \mathbf{X} :

$$J_{\text{nc}}(\mathbf{X}^T \hat{H}) \rightarrow \max_{\hat{H} : \text{s.d.}(\mathbf{X}^T \hat{H})=1}. \quad (3)$$

Ищем последовательные решения $\widehat{\mathbf{W}} = [\widehat{W}_1 : \dots : \widehat{W}_r]$ такие, что

$$\text{cov}(\mathbf{X}^T \widehat{W}_j, \mathbf{X}^T \widehat{W}_i) = 0, i \neq j.$$

Результат SSA-ICA:

$$S_j = \mathbf{X}^T \widehat{W}_j, j = 1, \dots, r, \quad (4)$$

$$\mathbf{X} = \sum_{i=1}^r \widehat{U}_i S_i^T, \text{ где } \widehat{\mathbf{U}} = (\widehat{\mathbf{W}}^T)^{-1}. \quad (5)$$

SSA-ICA с центрированием

Функционал: $J(Z) = \left(-\frac{1}{K} \sum_{l=1}^K G(z_l) + \mathbb{E}G(\nu) \right)^2$.

Обозначим r_c ранг $\mathbf{X} - \bar{\mathbf{X}}$.

В. Оптимизационная задача без центрирования для $\mathbf{X} - \bar{\mathbf{X}}$:

$$J\left((\mathbf{X} - \bar{\mathbf{X}})^T \hat{H}\right) \rightarrow \max_{\hat{H}: \text{s.d.}((\mathbf{X} - \bar{\mathbf{X}})^T \hat{H})=1} \quad (6)$$

Ищем последовательные решения $\widehat{\mathbf{W}} = [\widehat{W}_1 : \dots : \widehat{W}_{r_c}]$ такие, что $\text{cov}\left((\mathbf{X} - \bar{\mathbf{X}})^T \widehat{W}_j, (\mathbf{X} - \bar{\mathbf{X}})^T \widehat{W}_i\right) = 0, i \neq j$.

Результат SSA-ICA с центрированием:

$$S_j^{(c)} = (\mathbf{X} - \bar{\mathbf{X}})^T \widehat{W}_j, j = 1, \dots, r_c, \quad (7)$$

$$\mathbf{X} = \bar{\mathbf{X}} + \sum_{i=1}^{r_c} \widehat{U}_i \left(S_i^{(c)}\right)^T, \text{ где } \widehat{\mathbf{U}} = \left(\widehat{\mathbf{W}}^T\right)^{-1}. \quad (8)$$

SSA-ICA: Эквивалентность оптимизационных задач

Пусть ранги \mathbf{X} и $\mathbf{X} - \bar{\mathbf{X}}$ равны

Утверждение

Решения $\widehat{\mathbf{W}}$ оптимизационных задач A и B , с центрированием и без, совпадают.

Утверждение

Пусть $\mathbf{X} - \bar{\mathbf{X}} = \mathbf{U}^{(c)} (\boldsymbol{\Lambda}^{(c)})^{1/2} (\mathbf{V}^{(c)})^T$ — SVD разложение. Матрица \mathbf{W} — решение оптимизационной задачи без центрирования, применённой к $\mathbf{V}^{(c)}$. Тогда

$$\widehat{\mathbf{W}} = \mathbf{U}^{(c)} (\boldsymbol{\Lambda}^{(c)})^{-1/2} \mathbf{W}$$

решение обеих оптимизационных задач A и B .

Следствие: результаты о разделении центрированных подпространств можно перенести на случай нецентрированных.

SSA-ICA: Примеры разделимости рядов

Утверждение

$f_n^{(1)} = A_1 \sin(2\pi\omega_1 n + \gamma_1)$, $f_n^{(2)} = A_2 \sin(2\pi\omega_2 n + \gamma_2)$, $0 \leq n \leq N-1$.

Длина окна L такая, что $K\omega_j$, $j = 1, 2$ целые, $K = N - L + 1$,
 $0 < \omega_j < \frac{1}{2}$, $j = 1, 2$, $\omega_1 \neq \omega_2$, и $\omega_1 \neq 3\omega_2$, $\omega_2 \neq 3\omega_1$, и $\omega_1 + \omega_2 \neq \frac{1}{2}$.
 Тогда ряды сильно разделимы с помощью SSA-ICA.

Утверждение


Пусть $f_n^{(N,1)} = \exp \frac{\alpha n}{N}$ и $f_n^{(2)} = A \sin(2\pi\omega n + \gamma)$, $0 \leq n \leq N-1$. Тогда
 ряды асимптотически разделимы с помощью SSA-ICA при $K \rightarrow \infty$.

Утверждение

Пусть $f_n^{(1)} = a(n+1) + b$ и $f_n^{(2)} = A \sin(2\pi\omega n + \gamma)$, $0 \leq n \leq N-1$. Тогда
 ряды асимптотически разделимы с помощью SSA-ICA с
 центрированием при $K \rightarrow \infty$.

Реальный ряд

Ряд ежемесячных продаж белого сладкого вина в Австралии в тысячах литров в период с августа 1982 года по июнь 1994 года.




Реальный ряд: Взвешенные корреляции

$$F = \sum F^{(k)}$$


$\{\rho_w(F^{(i)}, F^{(j)})\}$ показывают степень разделения $F^{(i)}, F^{(j)}$.

Около нуля (белый цвет) — хорошая отделимость,
большие значения (черный или серый) — плохая.

a) Before ICA



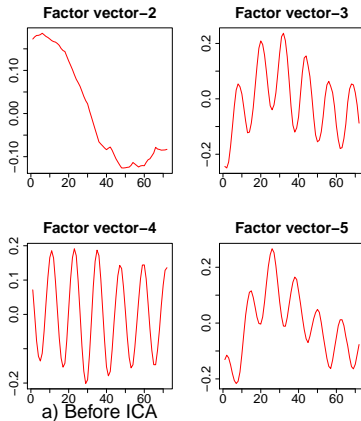
b) After ICA



Реальный ряд: базисы траекторных пространств строк

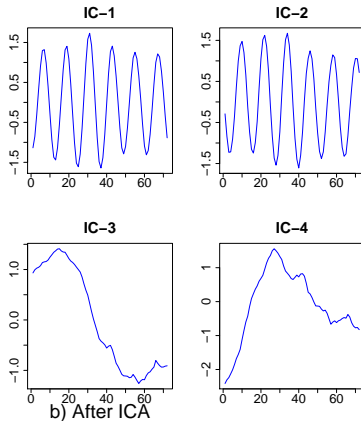
SSA

базис не разделяет









SSA-ICA

базис приближенно разделяет



Реальный ряд: Результат SSA-ICA



Результаты

- ① Выведены условия слабой и асимптотической разделимости центрированных подпространств.
- ② Условия были проверены для подпространств, представляющих: синусы с разными частотами (сильная разделимость), линейную функцию и синус, экспоненту и синус (асимпт. разделимость).
- ③ Были предложены две модификации метода SSA для разделения смешавшихся компонент: базовый вариант SSA-ICA и вариант SSA-ICA с центрированием.
- ④ Выведены условия разделимости рядов для SSA-ICA.
- ⑤ Проверены условия разделимости для следующих рядов: синусов с разными частотами (сильная разделимость), линейной функции и синуса, экспоненты и синуса (асимптотическая).
- ⑥ Продемонстрировано применение метода SSA-ICA на примере реальных данных.
- ⑦ Алгоритмы SSA-ICA и SSA-ICA с центрированием были реализованы на языке программирования R с использованием пакетов Rssa, fastICA.